

Soutenance SAE S6.01



IVAN VELJOVIC BULATOVIC
RYAN MARIA PAUL
MATHEW PRADES
INÈS MARCISZ

Sommaire

1) Analyse des
besoins

2) Méthodes de
travail

3) Architecture et
choix techniques

4) Intégration des
LLM et RAG

5) Déploiement

6) Défis et
difficultés

Analyse des besoins

- **Besoins fonctionnels** : compte utilisateur, sessions de conversation, historique, poser des questions de cuisine, 3 modes de réponse
- **Besoins non-fonctionnels** : pertinence des réponses, authentification sécurisée



Méthodes de travail

- Agile : sprints
- Jira : répartition et avancement des tâches
- Github : versionning, branches
- Communication et travail en équipe



Architecture et choix techniques


- Frontend : Angular (robustesse, adapté aux SPAs complexes, routing natif)
- Backend en couches : API (Flask) → Couche services / repositories (séparation des responsabilités)
- BDD + LLM externe + RAG/Web
- Documentation OpenAPI / Swagger



Flask


Intégration des LLM

- Connexion à OpenRouter, format des messages
- Mécanisme de fallback multi-modèles (robustesse)
- Construction du contexte / prompts



Retrieval-Augmented Generation (RAG)

- Pipeline du RAG: chargement PDF → chunking → embeddings → indexation FAISS
- Côté utilisateur : transforme prompt en embedding → recherche chunks proches + réponse en se basant sur le contexte
- Option bonus : recherche web + voix
- Comparaison des 3 modes (normal / rag / web) et pertinence de chacun



Déploiement

- **Conteneurisation**
- **Contraintes CORS**
- **Render + Railway**



Démonstration de l'application



Défis et difficultés

- Tests réalisés
- Difficultés rencontrées et solutions
- Point d'amélioration



Conclusion